

RAPPORT DE GESTION DE PROJET

Passage du POC au MVP : Chatbot Intelligent & Recommandations d'Événements (Puls-Events)

1. Analyse et synthèse des besoins formulés par l'équipe

1.1 Contexte et objectif du projet

Puls-Events propose une plateforme web permettant aux utilisateurs de découvrir et suivre des événements culturels en temps réel. À l'issue de la première phase de développement, un Proof of Concept (POC) de chatbot basé sur une architecture RAG a été déployé pour la recherche d'événements en Seine-Saint-Denis (93) sur une base d'environ 3 880 événements OpenAgenda.

Le POC actuel repose sur un jeu de données local ; le MVP devra donc prévoir une alimentation automatisée et actualisée des données afin de se rapprocher du fonctionnement en temps réel attendu par la plateforme.

L'évaluation RAGAS du POC a révélé des pistes d'amélioration majeures : le score de **Faithfulness** est de 0,575, la **Context Precision** de 0,422 et le **Context Recall** de 0,233. La faible valeur du *Context Recall* montre que certaines informations nécessaires pour répondre aux questions ne sont pas toujours récupérées par le retriever. Plusieurs pistes d'amélioration sont donc envisagées, notamment le filtrage géographique et par métadonnées dès le socle, puis la recherche hybride et le ré-ordonnancement (*reranking*) en évolutions complémentaires.

L'objectif de cette mission est de réaliser l'étude de design et le cadrage complet permettant de faire évoluer ce POC vers un **MVP fonctionnel, scalable et exploitable**, capable de répondre à des cas d'usage plus complexes et de mieux prendre en compte le contexte utilisateur.

1.2 Synthèse des besoins et défis techniques

L'équipe produit et technique a formulé quatre exigences prioritaires :

1. **Mémoire conversationnelle** : Conserver le contexte des échanges pour comprendre les questions de suivi (ex. « *Quels concerts sont prévus à Saint-Denis ?* » puis « *Lesquels sont gratuits ?* »).
2. **Prise en compte du contexte géographique** : Adapter les réponses du chatbot en fonction de la localisation de l'utilisateur ou d'une zone géographique spécifique.
3. **Recherche Web en temps réel** : Compléter la base d'événements interne lorsque l'information recherchée est absente ou nécessite une mise à jour récente.
4. **Monitoring des performances** : Suivre les indicateurs techniques (temps de réponse, erreurs, consommation des ressources) ainsi que les indicateurs de qualité des réponses.

1.3 Utilisateurs cibles et cas d'utilisation principaux

- **UC1 - Recherche avec localisation** : « *Quels événements culturels sont organisés près de chez moi ce week-end ?* »
- **UC2 - Enchaînement conversationnel** : « *Donne-moi plus de détails sur le premier concert. Y a-t-il un accès PMR ?* »

- **UC3 - Recherche d'information récente** : « Est-ce que le spectacle prévu ce soir est toujours maintenu ? »
(Déclenchement d'une recherche web si la donnée n'est pas présente en base interne).

2. Plan de projet, jalons et livrables

Note de cadrage : Le planning ci-dessous détaille les étapes de la mission d'étude de design et de cadrage. Les estimations en jours présentées dans le backlog (Section 3) correspondent à l'effort théorique de réalisation du MVP par l'équipe de développement et ne constituent pas la durée effective de la présente mission de cadrage.

2.1 Échéancier prévisionnel de la mission de cadrage (10 Semaines)

Semaine	Phase	Travaux principaux
S1	Cadrage	

Analyse des besoins métiers et retour d'expérience sur le POC.

S2	Veille technologique	
----	----------------------	--

Étude comparative des solutions Cloud et des bases vectorielles.

S3	Architecture	
----	--------------	--

Spécification de l'architecture technique cible du MVP.

S4	Backlog & Coûts	
----	-----------------	--

Priorisation des fonctionnalités et modélisation des coûts.

S5 - S6	Spécifications du socle	
---------	-------------------------	--

Cadrage détaillé de la mémoire conversationnelle et de la recherche géolocalisée.

S7	Spécifications Recherche Web	
----	------------------------------	--

Étude et intégration du mécanisme de recherche web complémentaire.

S8	Spécifications Monitoring	
----	---------------------------	--

Définition des indicateurs de suivi des performances et des erreurs.

S9	Recette du Cadrage & Tests	
----	----------------------------	--

Validation des schémas, tests de faisabilité et réévaluation RAGAS sur échantillon.

S10	Finalisation	
-----	--------------	--

Rédaction de la documentation, préparation de la présentation et du portfolio.

2.2 Jalons clés (Milestones)

- **J1 – Cadrage validé** : Périmètre fonctionnel et contraintes projet identifiés.
- **J2 – Architecture validée** : Choix des services Cloud et des technologies de stockage arrêtés.
- **J3 – MVP structuré** : Backlog priorisé et modèle financier défini.
- **J4 – Spécifications validées** : Mémoire, localisation et recherche web assemblées dans l'architecture.
- **J5 – Validation finale** : Dossier de cadrage validé et livraison du portfolio professionnel.

3. Macro Backlog des fonctionnalités (Priorisation MoSCoW)

3.1 Fonctionnalités indispensables (Must-Have)

ID	Fonctionnalité	Objectif / Description	Complexité	Estimation (Effort)
F01	Intégration et fiabilisation du socle RAG			

Maintenir et intégrer la recherche d'événements existante du POC dans la nouvelle architecture MVP.

Moyenne	
---------	--

2 j

F02	Mémoire conversationnelle	
-----	---------------------------	--

Conserver le contexte des échanges pour autoriser les questions de suivi.

Moyenne	
---------	--

4 j

F03	Prise en compte de la localisation	
-----	------------------------------------	--

Exploiter la géolocalisation et les adresses pour filtrer les résultats.

Moyenne	
---------	--

4 j

F04	Recherche web complémentaire	
-----	------------------------------	--

Déclencher un agent `smolagents` chargé d'utiliser un outil de recherche Web configuré lorsque la base interne est incomplète ou insuffisamment récente.

Élevée	
--------	--

5 j

F05	Gestion des sources	
------------	---------------------	--

Conserver et afficher l'origine des données (OpenAgenda ou Web) pour garantir la fiabilité.

Moyenne	
---------	--

2 j

F06	Monitoring et suivi applicatif	
------------	--------------------------------	--

Mesurer les temps de réponse, les erreurs et la consommation des ressources.

Moyenne	
---------	--

3 j

F07	Infrastructure scalable	
------------	-------------------------	--

Permettre au système de fonctionner sur un environnement Cloud évolutif (conteneurs, API).

Élevée	
--------	--

5 j

F08	Tests et validation	
------------	---------------------	--

Exécuter des tests automatisés (`pytest`) et réévaluer les métriques RAGAS.

Moyenne	
---------	--

3 j

Total	Socle Must-Have	Effort total de développement du socle		
--------------	------------------------	---	--	--

28 j

3.2 Fonctionnalités complémentaires (Nice-to-Have)

ID	Fonctionnalité	Objectif / Description	Complexité	Estimation (Effort)
F09	Recherche hybride			

Combiner la recherche sémantique (vectorielle) et la recherche textuelle (mots-clés BM25).

Moyenne	
---------	--

4 j

F10	Ré-ordonnement (<i>Reranking</i>)	
-----	-------------------------------------	--

Ré-ordonner les extraits récupérés pour ne garder que les plus pertinents.

Moyenne	
---------	--

3 j

F11	Filtres avancés	
-----	-----------------	--

Proposer des filtres stricts par date, catégorie, tarif ou accessibilité.

Moyenne	
---------	--

3 j

F12	Personnalisation des recommandations	
-----	--------------------------------------	--

Adapter la mise en avant des événements selon les préférences historiques de l'utilisateur.

Élevée	
--------	--

5 j

Total	Projet Complet	Must-Have (28 j) + Nice-to-Have (15 j)		43 j
-------	----------------	---	--	------

4. Architecture technique détaillée

4.1 Étude comparative des Cloud Providers

Afin de sélectionner la plateforme adaptée au MVP de Puls-Events, une grille d'évaluation comparative a été établie entre AWS, Microsoft Azure et Google Cloud Platform (GCP) :

Critère d'évaluation	AWS (Amazon Web Services)	Microsoft Azure	GCP (Google Cloud)
Services de conteneurs (API)	AWS ECS Fargate / App Runner (Très bon)	Azure Container Apps (Très bon)	Cloud Run (Très bon)
Scalabilité & Managed Vector DB	Partenariats nativement intégrés (Très bonne)	Bonne	Très bonne (Vertex Vector Search)
Monitoring & Télémétrie	CloudWatch / X-Ray (Très bon)	Azure Monitor (Très bon)	Cloud Monitoring (Très bon)
Services IA & LLM (API)	Bedrock / Intégration API externes	Azure OpenAI Service	Vertex AI
Facilité d'intégration Data / Dev	Excellente (écosystème mature)	Très bonne	Excellente
Pertinence globale pour le MVP	Très bonne	Bonne	Bonne

Justification du choix d'AWS :

AWS a été retenu principalement pour la maturité d'**Amazon ECS Fargate** (exécution de conteneurs serverless sans gestion de machines virtuelles), la simplicité d'intégration d'**ElastiCache Redis**, ainsi que la communauté très active autour de la conteneurisation d'API FastAPI et de pipelines RAG Python.

4.2 Composants de l'architecture retenue

À l'issue de l'analyse comparative, l'architecture cible du MVP s'appuie sur la combinaison de services suivants :


- **Exposition de l'API : Amazon API Gateway** pour exposer l'API FastAPI et constituer le point d'entrée du service.
- **Alimentation des événements** : un flux d'ingestion automatisé depuis **OpenAgenda** pour mettre à jour régulièrement les événements avant leur indexation dans Qdrant.
- **Service d'API Backend : Amazon ECS Fargate** pour héberger l'API FastAPI conteneurisée, avec possibilité d'adapter le nombre de tâches à la charge sans gérer directement les serveurs.
- **Base Vectorielle : Qdrant Cloud** retenue pour combiner recherche vectorielle et filtres par métadonnées, notamment les coordonnées géographiques. Il s'agit d'un service managé externe à AWS, choisi pour simplifier l'exploitation de la base vectorielle.
- **Mémoire Conversationnelle : Amazon ElastiCache for Redis** pour stocker l'historique des sessions utilisateurs à très faible latence.
- **Moteur d'Orchestration Agentique : LangGraph** (gestion du graphe de conversation) couplé à **smolagents** (Hugging Face) pour la recherche web sur déclenchement.
- **Monitoring & Observabilité : Amazon CloudWatch** (logs et CPU) et **LangSmith** (suivi de la qualité RAG et des coûts de tokens).

4.3 Représentation des flux de fonctionnement

Plaintext

[Source OpenAgenda] ■■■ (Ingestion / mise à jour des événements) ■■■ [Qdrant Cloud]

4.3 Représentation des flux



5.1 Coût du développement initial (Build)

L'estimation est calculée sur la base de l'effort de développement du socle indispensable (28 jours de développement et 2 jours de cadrage/documentation) en retenant un Taux Journalier Moyen (TJM) d'ingénierie de **400 € / jour** :

Poste de travail	Effort (Jours/Homme)	Coût Total (€ HT)
Cadrage, conception et choix des architectures Cloud	3 j	1 200 €
Développement de la mémoire conversationnelle	4 j	1 600 €
Intégration du contexte géographique	4 j	1 600 €
Intégration du mécanisme de recherche web	5 j	2 000 €
Déploiement de l'infrastructure Cloud	5 j	2 000 €
Mise en place du monitoring et de l'observabilité	3 j	1 200 €
Tests fonctionnels, de charge et validation qualité	4 j	1 600 €
Documentation technique et supports de présentation	2 j	800 €
TOTAL BUILD (Socle Must-Have)	30 jours	12 000 € HT

5.2 Coûts d'Exploitation Mensuels (OPEX) — Modélisation par charg

Les montants ci-dessous constituent une modélisation de cadrage estimée à partir d'hypothèses de volumétrie précises. Ces chiffres devront être affinés avec le calculateur officiel AWS avant la mise en production officielle.

Hypothèses retenues par scénario :

- **Scénario FAIBLE (Lancement / Tests) :** 1 000 requêtes/mois (~35 req/jour), ~500 tokens/req sur mistral-small-latest, instance Redis et ECS au niveau minimum.
- **Scénario MOYEN (Exploitation MVP) :** 50 000 requêtes/mois (~1 600 req/jour), ~800 tokens/req, 5 % d'appels à l'agent web, cluster Qdrant et Redis managés.
- **Scénario FORT (Montée en charge) :** 500 000 requêtes/mois (~16 000 req/jour), ~1 000 tokens/req, 10 % d'appels à l'agent web, haute disponibilité multi-AZ.

Composant / Service Cloud	Scénario FAIBLE (1 000 req/mois)	Scénario MOYEN (50 000 req/mois)	Scénario FORT (500 000 req/mois)

AWS ECS Fargate (API FastAPI)

15,00 €	45,00 €	180,00 €

Qdrant Cloud (Vector DB)

0,00 € (<i>Free Tier</i>)	35,00 €	120,00 €

ElastiCache Redis (Mémoire)

12,00 €	25,00 €	75,00 €

API Mistral AI (LLM & Embeddings)

5,00 €	85,00 €	650,00 €

Recherche Web (Agent smolagents)

0,00 €	15,00 €	110,00 €

CloudWatch & Monitoring Logs

5,00 €	20,00 €	80,00 €

TOTAL OPEX MENSUEL ESTIMÉ

37,00 € / mois	225,00 € / mois	1 215,00 € / mois
----------------	-----------------	-------------------

6. Bilan et justification de la démarche

Le passage du POC au MVP repose sur la consolidation du socle existant et la réponse aux limites observées lors des évaluations :

- **Qualité du Retrieval** : Le MVP prévoit d'abord une amélioration du filtrage et de la recherche géographique sur la base vectorielle. La recherche hybride et le ré-ordonnement (*reranking*) constituent des évolutions complémentaires (Nice-to-Have) pouvant améliorer davantage la qualité du retrieval à l'avenir.
- **Usage conversationnel** : L'intégration de la mémoire Redis permet de suivre un fil de discussion naturel.
- **Complétude des données** : L'agent web s'ajoute à l'agent s et apporte une réponse aux requêtes portant sur des événements récents ou absents de la base interne.
- **Pérennité technique** : La conteneurisation sur AWS ECS Fargate assure la scalabilité et le suivi continu du service.

7. Conclusion

Le cadrage proposé permet de passer d'un POC local à une architecture MVP plus robuste sans remettre en cause les acquis du prototype. Le socle RAG existant est conservé, puis complété par la mémoire conversationnelle, la prise en compte géographique, la recherche Web déclenchée lorsque nécessaire et un dispositif de monitoring. La priorité est donnée à une architecture simple à exploiter et capable d'évoluer avec la charge.

Les coûts et charges présentés dans ce document restent des estimations de cadrage. Ils devront être recalculés au moment de l'implémentation à partir du dimensionnement réel des services et des tarifs en vigueur.

8. Annexes & Portfolio professionnel

L'ensemble des réalisations techniques et projets du parcours Data Engineer sont documentés dans le portfolio

- **Lien vers le Portfolio GitHub** : <https://github.com/K93000/Passez-votre-systeme-IA-du-POC-au-MVP>

Répertoire des projets présentés sur GitHub :

1. POC_RAG_Evenements_93/ : Code source du prototype (FAISS, Streamlit, scripts de nettoyage, rapports d'évaluation RAGAS).
2. Design_MVP_Architecture/ : Dossier de cadrage, diagrammes d'architecture Cloud, spécifications OpenAPI / FastAPI et grilles tarifaires.
3. Projets_Data_Engineering/ : Projets du parcours illustrant la conception de pipelines de données, la gestion de bases de données vectorielles et le déploiement Cloud.